

浙江大学实验报告

(此页可在 <http://bksy.zju.edu.cn/office/> 下载)

课程名称： 磁共振成像原理及应用 实验类型： 仿真探究型

实验项目名称： 功能磁共振数据分析

学生姓名： 李凌哲 专业： 生物医学工程 学号： 3230100650

同组学生姓名： 未定

指导老师： 吴丹、张祎、丁秋萍

实验地点： 教六-204 实验日期： 2026 年 04 月 10 日

装
订
线

1 一、实验目的和要求（必填）

根据提供的 BOLD-fMRI 成像数据，完成大脑活跃区域的分析，体会该成像模态的原理与应用。

1. 掌握任务态功能磁共振的基本原理；
2. 熟悉数据格式和预处理；
3. 使用 SPM 处理功能磁共振数据。

作为拓展内容，也可以尝试自行使用代码实现。

2 二、实验内容和原理（必填）

2.1 BOLD-MRI 的物理原理

BOLD (Blood Oxygenation Level Dependent) 是 fMRI 最核心的对比度机制，这种成像模态的本质是通过血液中氧合血红蛋白和脱氧血红蛋白的磁学性质差异，

将神经活动转化为 MRI 信号的变化。当大脑某个区域的神经元激活时（产生动作电位和突触传递），需要消耗能量（ATP）；神经元消耗局部的氧气和葡萄糖增加，由此，为了补充氧气，局部的脑血流量（CBF, Cerebral Blood Flow）和脑血容量（CBV）会急剧增加；血流量增加的幅度将会超过氧代谢率增加的幅度，因此，在激活区域，新鲜的富氧血液大量涌入，导致该区域毛细血管和静脉端的脱氧血红蛋白（dHb）浓度不升反降。

2.1.1 血红蛋白的磁学特性与对比度机制

在先前的传统 MRI 中，我们提到 T_2^* 衰减的成因就在于除了量子力学现象约束下的弛豫（理解为自旋间的相互作用）之外，还有局部场不均匀的效应存在着。引起这种不均匀的因素有很多——梯度磁场的存在、化学位移的存在等，这些都会导致拉莫频率水平上的差异，使得即使是单一体素内也会存在不同的等色体，从而引发远快于理论弛豫的 FID 衰减。 T_2 自旋回波认为是在回波产生期间克服了这种场不均匀性，而梯度回波只是克服了梯度回波引入的部分不均匀性，也就是 T_2^* 衰减的成因。这一点我们在 LAB2 中也已经有提及了。

BOLD 也是这种场不均匀性的一大来源，只是此时我们不再将其视为造成信号衰减的障碍，而是图片对比度的一部分，包含着大脑活动的信息。也正是因为这个原因，BOLD 这种成像模态是不能使用自旋回波序列的。简而言之，BOLD 对比度其实是基于成像组织化学性质不变前提下， T_2^* 产生的对比度。也就是组织的 T_2 是相对稳定的（化学性质不变），但 T_2^* 可以随着时间变化，这种对比度就可以认为是由纯粹的生理学活动产生的，这也正是功能磁共振的含义。

血红蛋白的核心是一个卟啉环（Porphyrin ring），中间络合着一个二价铁离子 Fe^{2+} 。

- **1. 量子与分子层级：**血红蛋白的磁学性质由其中心铁离子的电子自旋态决定。含氧血红蛋白（Oxy-Hb）呈**抗磁性**，脱氧血红蛋白（dHb）因存在未成对电子呈**顺磁性**。局部磁场方程为：

$$B = (1 + \chi \cdot 10^{-6})B_0 \quad (1)$$

其中 $\chi_{oxy} < 0$, $\chi_{deoxy} > 0$ 。因此， $[dHb]$ 浓度直接决定局部磁化率。由此，血红蛋白在磁场背景中产生了一定的漂移和扭曲，为产生对比度提供了基础。

- **2. 介观物理层（磁场与散相）：**血管内 dHb 的存在导致血管内外产生磁化率差

$\Delta\chi$ ，进而在周围组织引起局部磁场畸变 ΔB 。水分子在此畸变场中扩散会导致质子自旋加速散相（Dephasing），使横向弛豫时间 T_2^* 缩短：

$$\frac{1}{T_2^*} = \frac{1}{T_2} + \gamma\Delta B \quad (2)$$

这也和前文提到的解释是相符合的。

BOLD 对于 K 空间编码影响的数学分析 在理想的 MRI 空间编码中，信号仅受我们施加的梯度场 $\mathbf{G}(t)$ 控制，k 空间轨迹定义为 $\mathbf{k}(t) = \gamma \int_0^t \mathbf{G}(\tau) d\tau$ 。但由于 BOLD 效应（脱氧血红蛋白的顺磁性），局部磁场产生了非均匀性 $\Delta B(\mathbf{r})$ 。真实信号方程变为图片中的形式：

$$S(t) = \int_{\text{Brain}} M_{xy}(\mathbf{r}) \cdot e^{-i\gamma\Delta B(\mathbf{r})t} \cdot e^{-i\mathbf{k}(t)\cdot\mathbf{r}} d^3\mathbf{r}$$

为了严谨分析，我们将积分域从整个大脑缩小到一个特定的**体素（Voxel）** V_0 内，其中心位置为 $\mathbf{r}_0$ 。此时，我们可以将局部磁场扰动 $\Delta B(\mathbf{r})$ 泰勒展开（分解为宏观均值与微观涨落）：

$$\Delta B(\mathbf{r}) = \overline{\Delta B}(\mathbf{r}_0) + \delta B(\mathbf{r})$$

* $\overline{\Delta B}(\mathbf{r}_0)$ ：体素内的宏观平均磁场偏移。* $\delta B(\mathbf{r})$ ：体素内微观尺度上（如毛细血管周围）的磁场不均匀涨落，满足在体素内积分为 0。单体素对总信号的贡献 $S_{V_0}(t)$ ：

$$S_{V_0}(t) = \underbrace{e^{-i\gamma\overline{\Delta B}(\mathbf{r}_0)t}}_{\text{宏观相位偏移}} \cdot \int_{V_0} M_{xy}(\mathbf{r}) \cdot \underbrace{e^{-i\gamma\delta B(\mathbf{r})t}}_{\text{微观自旋散相}} \cdot e^{-i\mathbf{k}(t)\cdot\mathbf{r}} d^3\mathbf{r}$$

我们使用的 GRE-SPI 序列，回波只是纠正梯度带来的相位偏差，不补偿以 BOLD 为代表的局部场不均匀效应带来的相位偏差。这是 T_2^* 衰减的一个具体的成因，而且它也可以用于产生对比度，因其可以接受来自生理活动带来的编码。

可能的拓展方向：非实数 MRI 图像分析 在 LAB1 中我们就提到过，K 空间重建 MRI 得到实数图像的前提是其具有 Hermitian Symmetry，也就是复共轭对称性。而这基于这样的物理学假设：体素乃至整个成像区域所有的等色团分割、相位差值的建立，都以梯度编码为唯一成因，因此，MRI 重建的结果就是纯粹由 PD 以及 T1/T2 理想弛豫过程（也就是基础的 Bloch 方程的描述）约束的信号响应强度分布。但是这显然是不可能的，局部场不均匀效应将会破坏这一假设。

BOLD 效应（以及任何磁场不均匀性）从根本上破坏了重建图像的实数性，使其变为复数图像：

$$I_{\text{complex}}(\mathbf{r}) = M_{xy}(\mathbf{r}) \cdot e^{-TE/T_2^*(\mathbf{r})} \cdot e^{-i\gamma\overline{\Delta B}(\mathbf{r})TE}$$


因为存在非零的局部磁场偏置，重建图像中产生、叠加了一个随空间变化的虚部，这破坏了信号的共轭对称性。我们在工程上通常只取**复数图像的模值 (Magnitude)**：

$$|I_{\text{complex}}(\mathbf{r})| = \sqrt{\text{Re}^2 + \text{Im}^2} = M_{xy}(\mathbf{r}) \cdot e^{-TE/T_2^*(\mathbf{r})}$$

通过绝对能量的水平，我们已经足以得到由 T_2^* 产生的对比度了。事实上这也是 BOLD-MRI 中使用的方案，同时也是为什么我们在 SPM/FSL 等软件里处理 fMRI 数据时，输入的大多是 Magnitude NIfTI 图像的原因。

在一般的成像中，只要有这种磁场梯度分布不完美的情景，复数图像的问题都会存在，我们一般将其视为误差，需要进行校正处理，但在 BOLD 成像模态中，复数相位也能编码神经活动，也包含了信息，因而可以称为分析的对象，例如 Phase-fMRI 这样的技术分支。


- **3. 生理层(神经血管耦合):**神经激活时, O_2 消耗增加, 但**脑血流量 (CBF) 的超代偿性暴增**远大于氧耗增加。大量富氧动脉血涌入, 产生“洗脱效应 (Washout)”, 导致局部静脉毛细血管内的 $[dHb]$ **不升反降**。这一点是基于生理学事实的, 我们在测量和分析时都必须依据这个事实。其实严格地说, $[dHb]$ 在过程刚开始时就有一个相对水平略微下降的过程, 一般称为 initial dip, 但是在工程上这个变化难以探测, 并未被广泛地应用于成像。
- **4. 宏观信号层(成像体现):**激活态下, $[dHb] \downarrow \implies \Delta B \downarrow \implies$ 质子散相变慢 $\implies$




T_2^* ↑。根据梯度回波信号公式：

$$S = S_0 e^{-\frac{TE}{T_2^*}} \quad (3)$$

T_2^* 的延长导致指数衰减项减小，最终表现为 MRI 图像上 1%~5% 的正向信号增强。





2.2 成像实践中的优化：GRE EPI 序列

大脑活动转瞬即逝，时效性极强，为提高大脑功能成像的时间分辨率，这对我们序列的扫描速度提出了更高的要求，之前的结构成像方法已经不再能满足需求，因此我们引入 GRE-EPI 序列——平面回波成像（EPI, Echo Planar Imaging）。

这个序列最大的特点就是追求极致的速度——ADC 的采样是常态化进行的，在一个周期内并不中断。在这个序列中，不同于传统结构成像每次单独重新进行相位编码，它只是通过短促的相位编码方向上（Phase Encoding）打出的一个极短促的脉冲（Blip）来进行 K 空间的换行，整个采集周期的相位编码都依赖于第一次的基准。此外，在频率编码方向上，EPI 的机理也是类似，不同于常规的单向扫描后换行，它是进行来回往复的扫描的，在 K 空间上以之字形的轨迹进行填充。最重要的是，**EPI 序列采集一张图像，RF 只激发一次**，这也是它省时间的一个重大原因。

这种激进的优化策略代价很大。首先，单次 RF 激发成像、漫长的读出窗口意味着严重的能量水平衰减，这势必降低图像的信噪比；K 空间横向正负交替来回填充，系统延迟、涡流等因素会导致相位对齐的问题。又因为**整个采集周期的相位编码都依赖于第一次的基准**，局部磁场不均匀 ΔB 、编码不完美的影响可以进行累积。此外，为了让读出梯度飞快地切换，EPI 必须使用非常高的接收带宽（Bandwidth）——本质上是磁场梯度提高，拉莫频率的分布范围就会增大。在信号处理中，带宽越宽，放进来的背景噪声就越多。

不过，我们使用 EPI 序列得到大脑活跃区域结果后，也可以与结构成像进行比对，结合不同成像模态的优势进行研究。

2.3 活跃区域的判定-SPM 与 GLM

在任务态 fMRI (Task-fMRI) 研究中，寻找大脑对特定刺激的“活跃区域”是核心目标。DPABI (Data Processing & Analysis for Brain Imaging) 的任务态模块本质上是对 SPM (Statistical Parametric Mapping) 核心统计引擎的高级封装。

设实验范式中，某一刺激事件的时间序列为冲激函数序列 $u(t)$ 。大脑物理的血流动力学响应函数 (Hemodynamic Response Function, HRF) 通常被建模为双伽马 (Double-Gamma) 函数 $h(t)$:

$$h(t) = A \left(\frac{t^{\alpha_1-1} e^{-t/\beta_1}}{\beta_1^{\alpha_1} \Gamma(\alpha_1)} - c \frac{t^{\alpha_2-1} e^{-t/\beta_2}}{\beta_2^{\alpha_2} \Gamma(\alpha_2)} \right) \quad (4)$$

其中，第一项刻画了刺激后 4-6 秒的主激活峰 (Peak)，第二项刻画了 10-15 秒左右的下沉期 (Undershoot)。注意，这个函数是直接刻画 BOLD 信号，也就是 MRI 的能量水平的，它并不是简单的脱氧血红蛋白浓度。

DPABI 在构建任务回归因子时，会将实验设计序列 $u(t)$ 与 HRF 进行连续时间卷积 (Convolution)，得到理论上预期的 BOLD 信号波动 $x(t)$:

$$x(t) = (u * h)(t) = \int_0^t u(\tau) h(t - \tau) d\tau \quad (5)$$

在离散时间点（即扫描的 TR 时间）进行采样后，这些 $x(t)$ 就构成了 GLM 中代表任务效应的列向量。这也是我们开始分析时，要给出 TR 时间和任务态的具体序列的原因——知道了理想状态，才能进行预测，而理想状态如何，则是以 HPF 为依据进行定义的。

接下来我们来到实际数据的层面进行分析：

SPM 将大脑分割成数十万个独立的三维体素 (Voxel)，在每一个体素上独立地拟合一个 GLM，最后在空间尺度上通过随机场理论 (RFT) 进行多重比较校正。对于大脑中的任意一个特定体素，其在整个扫描过程中记录下的 BOLD 信号时间序列可以表示为一个向量 Y ；这就是所谓的大规模单变量方法 (Mass-Univariate Approach)。

2.4 分块设计矩阵 (Partitioned Design Matrix)

对于某个特定体素，其在 N 个时间点上的 BOLD 信号向量为 $Y \in \mathbb{R}^{N \times 1}$ 。DPABI 构建的设计矩阵 $\mathbf{X}$ 被巧妙地分为两部分：**任务相关的解释变量** (X_{task}) 和

干扰协变量 (X_{nuis})。

$$Y = \mathbf{X}\beta + \epsilon = [X_{task} \mid X_{nuis}] \begin{bmatrix} \beta_{task} \\ \beta_{nuis} \end{bmatrix} + \epsilon \quad (6)$$

- X_{task} : 由上述卷积得到的**预期 BOLD 信号序列**构成 (例如: 刺激 A、刺激 B)。
- X_{nuis} : 这是 DPABI 预处理模块的强项。它通常自动包含 6 个头动参数、极低频漂移 (离散余弦变换 DCT 基函数), 甚至更复杂的 Friston-24 头动扩展项和整体白质/脑脊液信号。它们是这个物理模型中非理想的部分。
- ϵ : 未被模型解释的误差项。

这个矩阵实际上完成了对刺激下 BOLD 信号的**数学建模**——我们可以认为设计矩阵 X 的行索引就是时间本身, 而每一个列都是一个 BOLD 序列数据向量中**应当存在的一个时域序列成分**。在 X_{task} 中, 列向量就是由 HRF 和冲激函数序列 $u(t)$ 约束的一个理想响应时间序列 (所有的这些序列是相互叠加的关系); 而 X_{nuis} 则是我们不关注的噪音和干扰信号序列, 典型的如头动、线性漂移和常数项直流偏移等。 β 本质上是一系列**权重**, 它将 BOLD 信号描述为一系列理想响应序列和干扰分量的线性组合, 也是我们求解的对象。 ϵ 则是模型无法解释的, 真正的拟合偏差部分。

2.5 普通最小二乘法 (Ordinary Least Squares, OLS) 求解 β

给定一般线性模型:

$$Y = \mathbf{X}\beta + \epsilon \quad (7)$$

其中, $Y \in \mathbb{R}^{N \times 1}$ 是观测信号, $\mathbf{X} \in \mathbb{R}^{N \times P}$ 是设计矩阵, $\beta \in \mathbb{R}^{P \times 1}$ 是我们要估计的未知参数向量, $\epsilon \in \mathbb{R}^{N \times 1}$ 是残差。

我们的目标是找到估计值 $\hat{\beta}$, 使得残差平方和 (Sum of Squared Errors, SSE) 最小化。定义损失函数 $S(\beta)$:

$$S(\beta) = \epsilon^T \epsilon = (Y - \mathbf{X}\beta)^T (Y - \mathbf{X}\beta) \quad (8)$$

将上式展开：

$$S(\beta) = Y^T Y - Y^T \mathbf{X} \beta - \beta^T \mathbf{X}^T Y + \beta^T \mathbf{X}^T \mathbf{X} \beta \quad (9)$$

由于 $\beta^T \mathbf{X}^T Y$ 的计算结果是一个标量，其转置等于自身，即 $(\beta^T \mathbf{X}^T Y)^T = Y^T \mathbf{X} \beta$ ，因此上式可简化为：

$$S(\beta) = Y^T Y - 2\beta^T \mathbf{X}^T Y + \beta^T \mathbf{X}^T \mathbf{X} \beta \quad (10)$$

为了求极小值，我们对向量 β 求偏导，并令导数（梯度）为零向量：

$$\frac{\partial S}{\partial \beta} = -2\mathbf{X}^T Y + 2\mathbf{X}^T \mathbf{X} \beta = \mathbf{0} \quad (11)$$

化简后得到著名的正规方程 (Normal Equations)：

$$\mathbf{X}^T \mathbf{X} \beta = \mathbf{X}^T Y \quad (12)$$

假设设计矩阵的列是线性无关的（即 $\mathbf{X}$ 满秩，无多重共线性问题），则 $\mathbf{X}^T \mathbf{X}$ 是可逆方阵。两边同时左乘 $(\mathbf{X}^T \mathbf{X})^{-1}$ ，我们得到了 β 的解析解：

$$\hat{\beta}_{OLS} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T Y \quad (13)$$

2.6 时间自相关与预白化 (Pre-whitening)——广义最小二乘估计

在一般线性模型 (GLM) 的经典推导中，普通最小二乘法 (OLS) 依赖于一个极其严苛的假设：**高斯-马尔可夫定理 (Gauss-Markov Theorem)** 中的“**误差项独立同分布**”假设。然而，在真实的 fMRI 物理扫描中，这一假设被完全打破。以下的内容涉及一些有关随机过程的知识。

时间自相关 在纯粹的白噪声 (White Noise) 中，当前时刻的噪声与前一时刻的噪声是完全无关的。但在 fMRI 的 BOLD 信号中，体素的时间序列是由连续的 TR (重复时间，通常在 1.3 秒之间) 采样得到的。

时间自相关性是指：一个体素在 t 时刻的噪声残差 ϵ_t ，与其在 $t-1, t-2$ 时刻的噪声残差存在高度的相关性。导致这种现象的物理与生理原因主要包括：

1. **生理学噪声残留**：心跳（约 1 Hz）和呼吸（约 0.3 Hz）在相对较长的 TR 采样下会发生混叠（Aliasing），表现为低频波动。
2. **血流动力学迟滞**：BOLD 效应本质上是血流与血氧的物理缓冲过程，具有长达十余秒的拖尾效应（HRF），使得神经活动产生的未建模背景噪声也被“平滑”了。BOLD 信号在实际情况中也不会被我们定义的 $\mathbf{X}_{task}$ 所完全建模，肯定有一部分逸散到 ϵ 中，但其时间相关性依然存在。
3. **扫描仪物理特性**：磁场的不均匀性变化和射频线圈的发热会导致低频漂移（Low-frequency drifts）。

数学建模：一阶自回归模型 AR(1)

在 SPM 和 DPABI 中，通常使用 AR(1) 加上白噪声模型来近似刻画 fMRI 的时间自相关。即 t 时刻的误差项 ϵ_t 可表示为：

$$\epsilon_t = \rho\epsilon_{t-1} + z_t \quad (14)$$

其中， ρ 是自相关系数（对于 fMRI， ρ 通常在 0.1 ~ 0.3 之间，为正相关）， $z_t \sim \mathcal{N}(0, \sigma^2)$ 是真正的独立白噪声。

这种自相关性导致整个时间序列的误差协方差矩阵（Covariance Matrix） $\mathbf{V}$ 不再是单位矩阵 $\mathbf{I}$ 。其主对角线以外的元素不为零：

$$\text{Cov}(\epsilon) = E[\epsilon\epsilon^T] = \sigma^2\mathbf{V} = \sigma^2 \begin{bmatrix} 1 & \rho & \rho^2 & \cdots \\ \rho & 1 & \rho & \cdots \\ \rho^2 & \rho & 1 & \cdots \\ \vdots & \vdots & \vdots & \ddots \end{bmatrix} \quad (15)$$

在 OLS 下，参数估计量 $\hat{\beta}$ 依然是无偏的（Unbiased），即算出来的“信号幅度”基本没问题。致命的错误发生在对参数方差的估计上。

OLS 对方差的错误估计为：

$$\text{Var}_{OLS}(\hat{\beta}) = \hat{\sigma}^2(\mathbf{X}^T\mathbf{X})^{-1} \quad (16)$$

而真实的方差（在协方差为 $\sigma^2 \mathbf{V}$ 的情况下）应当是：

$$\text{Var}_{True}(\hat{\beta}) = \sigma^2 (\mathbf{X}^T \mathbf{X})^{-1} (\mathbf{X}^T \mathbf{V} \mathbf{X}) (\mathbf{X}^T \mathbf{X})^{-1} \quad (17)$$

数学证明表明，当序列存在正相关时，OLS 会严重低估残差的真实方差。由于我们在后续进行统计检验时的 T 统计量公式为：

$$T = \frac{\hat{\beta}}{\sqrt{\text{Var}(\hat{\beta})}} \quad (18)$$

方差被低估（分母变小），会导致算出来的 T 值被人为地异常放大！这就是为什么如果不处理自相关，会看到全脑都在“激活”（极高的假阳性率，Type I error）。

解决方案 fMRI 数据的噪声项 ϵ 存在高度的时间自相关（特别是短 TR 扫描），即 $\text{Cov}(\epsilon) = \sigma^2 \mathbf{V}$ ，其中 $\mathbf{V} \neq \mathbf{I}$ 。DPABI 底层调用 SPM 的 AR(1) 模型来估计协方差矩阵 $\mathbf{V}$ 。

为了获得无偏且方差最小的参数估计，模型使用一个白化矩阵 $\mathbf{W}$ （满足 $\mathbf{W}^T \mathbf{W} = \mathbf{V}^{-1}$ ）对原方程两边同时左乘，得到广义最小二乘估计（Generalized Least Squares, GLS）：

$$\hat{\beta}_{GLS} = (\mathbf{X}^T \mathbf{V}^{-1} \mathbf{X})^{-1} \mathbf{X}^T \mathbf{V}^{-1} \mathbf{Y} \quad (19)$$

对应的参数方差-协方差矩阵为：

$$\text{Var}(\hat{\beta}) = \hat{\sigma}^2 (\mathbf{X}^T \mathbf{V}^{-1} \mathbf{X})^{-1} \quad (20)$$

既然误差项具有“颜色”（即频谱上偏向低频，存在自相关，称为色噪声 colored noise），我们可以在求解 GLM 之前，使用一个数学滤波器将其“漂白”成独立的白噪声（White noise）。

假设我们通过受限最大似然估计（ReML）已经估算出了误差的协方差结构 $\mathbf{V}$ 。因为 $\mathbf{V}$ 是对称正定矩阵，我们可以找到一个白化矩阵 $\mathbf{W}$ ，使得：

$$\mathbf{W}^T \mathbf{W} = \mathbf{V}^{-1} \quad (21)$$

(在工程实现上, $\mathbf{W}$ 通常通过对 $\mathbf{V}^{-1}$ 进行 Cholesky 分解获得)。

我们将这个白化矩阵 $\mathbf{W}$ 左乘到原始的 GLM 方程的两边:

$$\mathbf{WY} = \mathbf{WX}\boldsymbol{\beta} + \mathbf{W}\boldsymbol{\epsilon} \quad (22)$$

令 $Y^* = \mathbf{WY}$, $\mathbf{X}^* = \mathbf{WX}$, $\boldsymbol{\epsilon}^* = \mathbf{W}\boldsymbol{\epsilon}$, 得到新的转换方程:

$$Y^* = \mathbf{X}^*\boldsymbol{\beta} + \boldsymbol{\epsilon}^* \quad (23)$$

现在, 让我们来检验一下新的误差项 $\boldsymbol{\epsilon}^*$ 的协方差矩阵:

$$\begin{aligned} \text{Cov}(\boldsymbol{\epsilon}^*) &= E[(\mathbf{W}\boldsymbol{\epsilon})(\mathbf{W}\boldsymbol{\epsilon})^T] \\ &= \mathbf{W}E[\boldsymbol{\epsilon}\boldsymbol{\epsilon}^T]\mathbf{W}^T \\ &= \mathbf{W}(\sigma^2\mathbf{V})\mathbf{W}^T \\ &= \sigma^2\mathbf{W}(\mathbf{W}^T\mathbf{W})^{-1}\mathbf{W}^T \quad (\text{因为 } \mathbf{V} = (\mathbf{W}^T\mathbf{W})^{-1}) \\ &= \sigma^2\mathbf{I} \end{aligned} \quad (24)$$

经过神奇的数学变换, 新的误差项 $\boldsymbol{\epsilon}^*$ 的协方差矩阵变成了 $\sigma^2\mathbf{I}$! 此时, 自相关性被完全消除, 误差项重新满足了独立同分布 (IID) 假设。

此时, 我们再对转换后的新方程应用普通的 OLS, 就等价于所谓的**广义最小二乘法 (Generalized Least Squares, GLS)**:

$$\hat{\boldsymbol{\beta}}_{GLS} = (\mathbf{X}^{*T}\mathbf{X}^*)^{-1}\mathbf{X}^{*T}Y^* = (\mathbf{X}^T\mathbf{V}^{-1}\mathbf{X})^{-1}\mathbf{X}^T\mathbf{V}^{-1}Y \quad (25)$$

它可以有效地应对误差自相关的问题, 通过引入权重矩阵 $\mathbf{V}$ 的校正来保证算出来的参数是方差最小的**最优解**。

2.7 活跃区域判定

在复杂的实验设计中, 设计矩阵 $\mathbf{X}$ 包含多个列 (如任务 A、任务 B、头动等), 对应多个 β 值 ($\beta_1, \beta_2, \dots, \beta_P$)。我们通常不直接考察单独的 β , 而是考察它们的线性组合, 即**对比效应量 (Effect Size, E)**。

我们定义一个行向量 $\mathbf{c}^T = [c_1, c_2, \dots, c_P]$, 称为对比向量。

- 若检验 “任务 A 是否有显著激活”: $\mathbf{c}^T = [1, 0, 0, \dots, 0]$ 。此时 $E = \mathbf{c}^T\hat{\boldsymbol{\beta}} = \hat{\beta}_1$ 。

- 若检验“任务 A 的激活是否显著大于任务 B”： $\mathbf{c}^T = [1, -1, 0, \dots, 0]$ 。此时 $E = \mathbf{c}^T \hat{\boldsymbol{\beta}} = \hat{\beta}_1 - \hat{\beta}_2$ 。

一般而言， $\boldsymbol{\beta}$ 的参数大小是和对应的成分在 BOLD 信号的强度呈现正相关的，我们可以从这个角度直观地理解对比效应量的概念。

判定是否活跃，不能仅看效应量 E 的大小，必须用效应量除以其估计的标准误 (Standard Error, SE)，得到 T 统计量。这相当于计算信噪比 (Signal-to-Noise Ratio)。如果一个体素位置虽然其 E 的值很高，但若其标准误很大，说明在原始数据的随机性下这很可能是偶然情形，缺乏可信度。这也是我们在 SPM 中使用的 **T-contrast** 的含义所在。

根据 GLS 的方差推导结果，参数向量 $\hat{\boldsymbol{\beta}}$ 的协方差矩阵为：

$$\text{Cov}(\hat{\boldsymbol{\beta}}) = \hat{\sigma}^2 (\mathbf{X}^T \mathbf{V}^{-1} \mathbf{X})^{-1} \quad (26)$$

其中， $\hat{\sigma}^2$ 是根据残差 $\boldsymbol{\epsilon}^*$ 算出的方差无偏估计。

因此，对比效应量 $\mathbf{c}^T \hat{\boldsymbol{\beta}}$ 的方差为：

$$\text{Var}(\mathbf{c}^T \hat{\boldsymbol{\beta}}) = \mathbf{c}^T \text{Cov}(\hat{\boldsymbol{\beta}}) \mathbf{c} = \hat{\sigma}^2 \mathbf{c}^T (\mathbf{X}^T \mathbf{V}^{-1} \mathbf{X})^{-1} \mathbf{c} \quad (27)$$

据此，该体素的 T 统计量定义为：

$$T = \frac{\text{Effect Size}}{\text{Standard Error}} = \frac{\mathbf{c}^T \hat{\boldsymbol{\beta}}}{\sqrt{\hat{\sigma}^2 \mathbf{c}^T (\mathbf{X}^T \mathbf{V}^{-1} \mathbf{X})^{-1} \mathbf{c}}} \quad (28)$$

软件会在全脑十万个体素上重复上述计算，生成一张三维的 T 值空间分布图，即所谓的 **统计参数映射图 (Statistical Parametric Map, SPM{T})**。这个 T 值越高，我们才认为此处存在激活的可信度越高。

2.8 多重比较校正

拿到全脑的 T-map 后，由于我们对全脑约 $N \approx 100,000$ 个体素同时进行了十万次独立的 T 检验，如果采用常规的单次检验显著性水平（如 $\alpha = 0.05$ ），仅凭随机噪声就会产生 $100,000 \times 0.05 = 5,000$ 个假阳性“活跃体素”。这就要求我们必须进行多重比较校正。

传统的 Bonferroni 校正 ($\alpha' = \alpha/N$) 在 fMRI 中过于严苛，因为它假设所有体素是完全独立的。而实际上，大脑的 BOLD 信号在空间上是高度连续的（存在

空间平滑)。

因此, DPABI 和 SPM 采用高斯随机场理论 (Gaussian Random Field Theory, GRF) 或排列检验 (Permutation Test) 来界定最终的活跃区域。以 GRF 为例, 判定逻辑通常采用双阈值法 (Dual-thresholding):

1. **体素形成阈值 (Voxel-level Threshold)**: 首先设定一个较高的初筛阈值 (如 $P_{\text{voxel}} < 0.001$)。在此阈值之上, 幸存的体素在空间上连结形成若干个“团块” (Clusters)。
2. **团块水平阈值 (Cluster-level Threshold)**: GRF 理论利用欧拉示性数期望公式, 计算在给定的空间平滑度 (FWHM) 和搜索体积下, 仅由纯噪音形成特定体积大小团块的概率。我们只保留那些**体积足够大, 大到不可能是由于随机噪音巧合形成的团块** (如 $P_{\text{cluster_FWER}} < 0.05$) ——**因为大脑的激活是区域性的, 相邻体元的 BOLD 信号并不是相互独立的, 头动等噪声对同一脑区的影响也很相似。**

只有那些 T 值极高 (突破体素阈值), 且在空间上广泛聚集 (突破团块阈值) 的脑区, 才会在结果图像中被“点亮” (通常用暖色调如红黄颜色渲染), 这也就是我们在 fMRI 论文中最终看到的“判定活跃区域”。

个体的分析只是基础, 其实神经科学研究更关注的是**群体水平 (Group-level)** 的共性, 因此以上的数据结果还需进行多样本的进一步处理和分析。由于我们本次实验只涉及单个样本, 所以此处不再展开了。

3 三、主要仪器设备与软件使用

PC, MATLAB 2025a, DPABI (BOLD 图像分析和处理)。

4 四、操作方法与实验步骤

4.1 DPABI 的使用与处理的 pipeline

接下来我们将结合参数讲解一下 BOLD MRI 处理的 Pipeline, 以及每一步的意义。下文中所涉及的参数都是基于给出的数据已知的。

基本参数设定 (Basic Parameters)

- **Time Points (156):** 扫描获得的时间点 (Volume) 数量。
- **TR = 2s (Repetition Time):** 射频脉冲 (RF) 的重复时间。
 - **物理意义:** TR 决定了自旋系统在两次激励之间纵向磁化矢量 (Longitudinal Magnetization, M_z) 恢复的时间。BOLD 信号来源于组织内部去氧血红蛋白浓度变化导致的 T_2^* 弛豫时间变化, 其信号强度的基本形式可近似表示为:

$$S = M_0(1 - e^{-\frac{TR}{T_1}}) \sin \alpha \cdot e^{-\frac{TE}{T_2^*}} \quad (29)$$

其中 TE 是回波时间, α 是翻转角 (Flip Angle)。

格式转换 (EPI/T1 DICOM to NIFTI)

- **工程目的:** 将核磁扫描仪直接导出的、按每层切片分散保存的 DICOM 格式, 转化为便于科学计算的 3D/4D 矩阵格式 (NIfTI, 即 .nii)。
- **细节:** NIfTI 头文件 (Header) 中会包含仿射变换矩阵 (Affine Matrix), 精确记录了图像体素 (Voxel) 与扫描仪物理坐标系 (Scanner Space) 的映射关系。

移除前时间点 (Remove First 6 Time Points)

- **工程目的:** 受试者刚进入机器时存在心理适应期; 且磁共振系统在刚开始扫描时, 纵向磁化矢量尚未达到稳态 (Steady State), 前几个 Volume 的信号强度会异常偏高且不稳定。同时, 真正的任务周期也在这 6 个时间点 (也就是采集时间的前 12s 后才开始的)。
- **数学物理原理:** 在连续的射频脉冲激励下, 纵向磁化矢量 M_z 的演化方程为:

$$M_z(n) = M_0(1 - e^{-\frac{TR}{T_1}}) + M_z(n-1) \cos \alpha \cdot e^{-\frac{TR}{T_1}} \quad (30)$$

当 $n \rightarrow \infty$ 时 (通常经过 3-5 个 TR), 磁化矢量达到 Ernst 稳态:

$$M_{ss} = M_0 \frac{1 - e^{-\frac{TR}{T_1}}}{1 - \cos \alpha \cdot e^{-\frac{TR}{T_1}}} \quad (31)$$

- **参数意义：**设置 6 表示直接剔除前 $6 \times 2\text{s} = 12$ 秒的数据，确保后续分析基于稳态信号。

时间层校正 (Slice Timing)

- **工程目的：**大部分 2D EPI 序列是逐层采集的。在同一个 TR (2s) 内，第一层和最后一层的采集时间存在显著差异。此步利用插值算法将所有层的时间对齐到同一个参考时间点，以消除时间相位差。
- **数学原理：**通常使用基于傅里叶变换的 Whittaker-Shannon 理想插值 (Sinc 插值) 来重建时间序列：

$$x(t) = \sum_{n=-\infty}^{\infty} x[n] \text{sinc} \left(\frac{t - n \cdot TR}{TR} \right) \quad (32)$$

其中，sinc 函数定义为：

$$\text{sinc}(x) = \frac{\sin(\pi x)}{\pi x} \quad (33)$$

- **参数意义：**
 - **Slice Order [1 3 5 7 9 ...]：**典型的隔层扫描 (Interleaved)，常用于 Siemens 机器，旨在避免相邻切片间的射频串扰 (Cross-talk effect)。
 - **Reference Slice 0：**代表由程序自动读取头文件或使用中间层作为对齐基准，以最小化整体的时间插值误差。

头动校正 (Realign)

- **工程目的：**校正受试者在扫描过程中不可避免的头部微动。
- **数学原理：**这是一个**刚体变换 (Rigid-body Transformation)**过程，具有 6 个自由度 (3 个平移, 3 个旋转)。设目标图像为 $I_t(\mathbf{x})$ ，参考图像为 $I_{ref}(\mathbf{x})$ ，空间坐标 $\mathbf{x} = [x, y, z]^T$ 。刚体变换模型为 $\mathbf{x}' = \mathbf{R}\mathbf{x} + \mathbf{t}$ 。目标函数为最小化误差平方和 (Sum of Squared Differences, SSD)：

$$\hat{\theta} = \arg \min_{\theta=\{\mathbf{R}, \mathbf{t}\}} \sum_i [I_t(\mathbf{x}_i) - I_{ref}(\mathbf{R}\mathbf{x}_i + \mathbf{t})]^2 \quad (34)$$

通常通过高斯-牛顿迭代法求解。此步骤生成的头动参数将在后续的统计分析中作为协变量 (Covariates) 被回归掉。

功能像与结构像配准 (T1 Coreg to Fun)

- **工程目的**: 功能像空间分辨率低、缺乏解剖细节; 结构像 (T1) 分辨率高且灰白质对比度好。通过配准, 为后续将功能信号映射到标准解剖空间建立桥梁。
- **数学原理**: 由于 T1 和 T_2^* 图像的组织对比度完全不同, 传统的 SSD 代价函数不再适用。常采用归一化互信息 (Normalized Mutual Information, NMI) 作为配准的目标函数:

$$NMI(A, B) = \frac{H(A) + H(B)}{H(A, B)} \quad (35)$$

其中 $H(A) = -\sum p(a) \log p(a)$ 为图像的信息熵 (Entropy), $H(A, B)$ 为联合信息熵。最大化 NMI 意味着两幅跨模态图像的解剖结构达到最佳匹配。

组织分割与 DARTEL 模板构建 (New Segment + DARTEL)

- **工程目的**:
 1. 将 T1 图像精确分割为灰质 (GM)、白质 (WM) 和脑脊液 (CSF)。
 2. 利用 DARTEL 算法将个体大脑进行高度非线性配准, 极大地提升群体空间中皮层沟回对齐的精度。
- **数学原理**:
 - **统一分割 (Unified Segmentation)**: 基于高斯混合模型 (GMM), 联合偏置场 (Bias Field) 估计进行概率计算:

$$P(y_i | \mu, \Sigma, \gamma) = \sum_{k=1}^K \gamma_k(\mathbf{x}_i) \mathcal{N}(y_i | \mu_k, \Sigma_k) \quad (36)$$

- **DARTEL 算法**: 基于微分同胚原理, 保证形变场平滑且拓扑结构不撕裂。利用稳态速度场 (Flow field) $\mathbf{v}$ 来参数化形变 ϕ :

$$\frac{d\phi_t}{dt} = \mathbf{v}(\phi_t) \quad (37)$$

- **参数意义**: 选择 East Asian 大脑模板作为仿射正则化 (Affine Regularisation) 先验, 能针对东亚人群获得更好的初等配准效果。

空间标准化 (Normalize)

- **工程目的:** 将所有受试者的数据重采样到一个统一的标准解剖空间(如 MNI152), 以实现组水平 (Group-level) 的统计学比较。
- **参数意义:**
 - **Bounding Box [-90 -126 -72; 90 90 108]:** 规定输出图像在 MNI 空间中的坐标起止范围 (单位: mm)。
 - **Voxel Size [3 3 3]:** 重采样后的体素分辨率。
 - **Normalize by DARTEL:** 应用上一步计算出的高精度非线性流场 ϕ 对 EPI 图像进行形变处理。

空间平滑 (Smooth)

- **工程目的:**
 1. 提高图像的信噪比 (SNR)。
 2. 弥补跨被试空间标准化后残存的解剖微小差异。
 3. **统计学假设需求:** 使数据更接近高斯随机场分布, 从而满足多重比较校正 (如基于 Random Field Theory 的 FWE 校正) 的严苛假设。
- **数学原理:** 使用三维高斯核与图像进行空间卷积计算:

$$G(x, y, z) = \frac{1}{(2\pi\sigma^2)^{3/2}} e^{-\frac{x^2+y^2+z^2}{2\sigma^2}} \quad (38)$$

$$I_{smoothed}(\mathbf{x}) = I_{raw}(\mathbf{x}) * G(\mathbf{x}) \quad (39)$$

- **参数意义:** **FWHM [6 6 6]** (半高全宽, Full Width at Half Maximum), 表示三维高斯平滑核在各个方向上的宽度尺寸 (单位: 毫米)。其与高斯核标准差 σ 的数学关系为:

$$FWHM = 2\sqrt{2\ln 2} \sigma \approx 2.3548 \sigma \quad (40)$$

其中 σ 为高斯分布的标准差, FWHM 与 σ 的单位保持一致 (通常为毫米)。

DPARSFA

— □ ×

Data Processing Assistant for Resting-State fMRI

Advanced Edition DPARSFA

Working Directory:

D:\MRI_PRO\MRILAB3\BOLDDATA

Participants

Sub_01

Time Points:

156

TR (s):

2

Template Par...

☒ EPI DICOM to NIFTI

☒ T1 DICOM to NIFTI

☐ BIDS to DPARSF

☐ Apply Mats

☒ Remove First

6

Time Points

☒ Slice Timing

Slice Number:

36

Slice Order:

[0 1430 88]

Reference Slice:

0

FieldMap Correction

☒ Realign

☐ Voxel-Specific Head Motion

☒ Reorient Fun*

☒ AutoMask

☐ Crop T1

☒ Reorient T1*

☒ Bet

☒ T1 Coreg to Fun

☐ Segment

☒ New Segment + DARTEL

Affine Regularisation in

☒ East Asian

☐ European

☐ Nuisance Covariates Regression

Polynomial

1

Head Motion

☐ Rigid-body 6

☐ Derivative 12

☒ Friston 24

☐ Voxel-specific 12

☐ Head motion scrubbing regressors

Nuisance regressors (WM, CSF, Global)

☐ Other covariates

☐ Add mean back

Filter (Hz):

0.01

~

0.1

☒ Normalize

Bounding Box:

[-90 -126 -72;90]

Voxel Size:

[3 3 3]

☐ Normalize by using EPI templates

☐ Normalize by using T1 image unified segmentation

☒ Normalize by DARTEL

☒ Smooth

☐ Smooth by DARTEL

FWHM:

[6 6 6]

☒ Default mask

☐ No mask

☐ User-defined mask

Use Default Mas

☐ Warp Masks into Individual Space

☐ Detrend

☐ Nuisance Covariates Regression

☐ ALFF+fALFF

Band (Hz):

0.01

~

0.1

☐ Filter

☐ Scrubbing

☐ ReHo

Cluster:

☐ 7

☐ 19

☒ 27 voxels

☐ Smooth ReHo

☐ Degree Centrality

☐ Functional Connectivity

☐ Extract ROI time courses

Define ROI

☐ Define ROI Interactively*

☐ CWAS

☐ Normalize to Symmetric Template

☐ Smooth

☐ VMHC

☐ Normalize Derivatives

☐ Smooth Derivatives

Parallel Workers #:

0

Functional Sessions #:

1

Starting Directory Name:

FunRaw

Help


Save

Load

Utilities

Quit

Run



4.2 参数具体配置

DPABI 只支持完成预处理，接下来的具体处理是由 SPM 本体来完成的：

我们按照 PPT 实验资料中给出的操作方法，完成了 β 所对应的 T 对比度的计算，并根据上文解释的详细算法进行了推断，得到激活置信区域，完成了相应的可视化。我们使用的是 SPM 的 Specify 1st-level 功能，也就是个体水平的分析，因为我们只有单个数据样本。


5 五、实验数据记录和处理

实验结果和资料示例相比对，大致是符合预期的。通过立体化不同视角的渲染，我们可以更直观地查看激活的脑部区域。

6 六、实验结果与分析（必填）

7 七、讨论、心得

注：不同类型的实验课对实验报告可有不同要求，各个学科的实验报告可以根据自己的




Statistics: *p-values adjusted for search volume*

set-level		cluster-level				peak-level							
p	c	PFWE-corr	qFDR-corr	k _E	p _{uncorr}	PFWE-corr	qFDR-corr	T	(Z _E)	p _{uncorr}	mm	mm	mm
0.000	16	0.000	0.000	477	0.000	0.000	0.000	19.94	Inf	0.000	36	-18	51
						0.000	0.000	13.84	Inf	0.000	33	-21	72
		0.000	0.000	786	0.000	0.000	0.000	14.95	Inf	0.000	-9	-99	0
						0.000	0.000	13.41	Inf	0.000	-18	-90	9
						0.000	0.000	11.26	Inf	0.000	-9	-87	-12
		0.000	0.000	651	0.000	0.000	0.000	14.61	Inf	0.000	15	-93	6
						0.000	0.000	12.47	Inf	0.000	24	-90	24
						0.000	0.000	11.04	Inf	0.000	9	-78	-6
		0.000	0.000	79	0.000	0.000	0.000	9.50	Inf	0.000	-18	-51	-24
						0.002	0.057	5.75	5.44	0.000	-6	-63	-12
		0.000	0.001	20	0.001	0.000	0.000	7.71	7.02	0.000	-48	-51	6
		0.000	0.001	22	0.000	0.000	0.003	6.44	6.01	0.000	-3	0	45
		0.001	0.049	7	0.024	0.000	0.003	6.43	6.00	0.000	15	-15	39
		0.002	0.051	6	0.035	0.001	0.024	5.96	5.61	0.000	-51	-27	18
		0.004	0.088	4	0.077	0.002	0.066	5.71	5.40	0.000	-48	-6	3
		0.000	0.011	12	0.005	0.003	0.078	5.66	5.36	0.000	12	-3	63
		0.002	0.051	6	0.035	0.004	0.108	5.57	5.28	0.000	-45	3	48
		0.003	0.063	5	0.051	0.008	0.176	5.44	5.17	0.000	51	-27	15
		0.003	0.063	5	0.051	0.012	0.256	5.34	5.08	0.000	-6	-6	63
		0.002	0.051	6	0.035	0.013	0.269	5.32	5.07	0.000	-18	-57	-54
		0.010	0.213	2	0.199	0.019	0.394	5.22	4.98	0.000	-45	3	33
		0.018	0.362	1	0.362	0.035	0.692	5.06	4.84	0.000	39	-18	9

table shows 3 local maxima more than 8.0mm apart

Height threshold: T = 4.97, p = 0.000 (0.050)
Extent threshold: k = 0 voxels
Expected voxels per cluster, <k> = 1.298
Expected number of clusters, <c> = 0.05
FWEp: 4.968, FDRp: 5.962, FWEc: 1, FDRc: 7

Degrees of freedom = [1.0, 138.0]
FWHM = 11.4 11.2 9.8 mm mm mm; 3.8 3.7 3.3 {voxels}
Volume: 1797174 = 66562 voxels = 1275.7 resels
Voxel size: 3.0 3.0 3.0 mm mm mm; (resel = 46.17 voxels)



学科特点做适当的调整，但上述基本内容中的第一、二、三、六条为必须填写的内容。